

风电场协同强化学习：从理论到高保真数字孪生

45 分钟演说稿

配套幻灯片：`slides/introduction_slides.tex`（48 帧，8 个章节）

建议节奏：动机 5' · 理论 6' · 收敛 5' · 基准 5' · 我们的工作 8' · 系统架构 9' · 路线图 5' · 问答缓冲 2'

全程口径：讲"我们做了什么、为什么这么做、测出了什么"，不夸大结论。凡是"没崩"与"对了"要分清。

0. 开场（30 秒）

各位好。今天这个报告分两条线。一条是理论线：多智能体强化学习凭什么能在风电场这种"每台机组只看得见局部、却要协同"的问题上收敛。另一条是工程线：我们把这套理论落到了一个真实的高保真仿真器上，并且把它做成了一个可以"建风场、接数据、训策略、看三维"的应用。

我想强调的一点贯穿全场："程序没报错"和"结果是对的"是两件事。这个报告里每一个结论，我都会尽量给出它对应的、可观测的判据——是像素、是计数器、是毫秒、是逐位比对，而不是"跑通了没抛异常"。

第一节 · 动机：尾流、协同与一个理论谜题（5 分钟）

1.1 尾流是什么问题

先讲物理。一台风机从风里取走能量，它下游会留下一条尾流——风速更低、湍流更强的一段区域。下游的机组如果正好站在这条尾流里，发的电就少。风电场里机组密集排布，这个相互遮挡的损失能到全场的 10% 到 20%。

有一个反直觉的解法叫尾流偏转（wake steering）：让上游机组故意偏航，把机头偏离正对风向一个角度。这台机组自己会少发一点电，但它的尾流被推向一侧，下游机组避开了遮挡，全场总功率反而上升。这是一个典型的"牺牲局部、优化全局"的协同问题。

1.2 为什么用多智能体 RL

那为什么要用强化学习、而且是多智能体的？

因为这个问题有三个特点：第一，动作是连续的——偏航角度、桨距角、发电机转矩都是连续量；第二，每台机组只能看到局部信息——它不知道整个风场的流场，只有自己和邻近的一点观测；第三，机组之间通过尾流耦合——我的动作要过几十秒才影响到下游。

集中式的优化在真实风场里不现实（通信、可扩展性都是问题），所以我们希望每台机组是一个独立的智能体，各自学习、但整体协同。这就落到了多智能体 RL 的框架里。

1.3 理论谜题

这里就有一个谜题。多智能体 RL 有个著名的困难：当每个智能体独立学习时，其他智能体也在变，从单个智能体的视角看，环境是"非平稳"的——马尔可夫性质被破坏，收敛的理论保证就没了。

但经验上，独立学习在风电场这类问题上**work**。这中间的缝隙，就是下一节理论要填的：凭什么独立学习能收敛？

第二节·理论基础：部分可观协同问题的 RL（6 分钟）

2.1 从 Dec-POMDP 到 TI-Dec-MDP

标准的建模是 **Dec-POMDP**（分布式部分可观马尔可夫决策过程）——这是已知最难的一类问题，一般情况下求解是 NEXP-完全的，实践中不可解。

关键的洞察来自我们参考的核心论文：风电场问题有特殊结构。尾流是单向传播的——上游影响下游，下游不影响上游，这是一个无环依赖结构（acyclic dependence）。利用这个结构，可以把问题重构成一个 **TI-Dec-MDP**（时间不变的分布式 MDP），复杂度大幅下降。

2.2 部分可观即马尔可夫噪声

第二个关键论点，我认为是整条理论线里最漂亮的一步：部分可观性可以被吸收成马尔可夫噪声。

意思是，当一个智能体看不到全局状态时，它看不到那部分——包括其他智能体的行为——在合适的假设下，可以被当成一个满足马尔可夫性质的随机噪声来处理。一旦这样重构，单个智能体面对的就重新变回了一个良定义的 **MDP**，标准 RL 的收敛工具就能用了。这就是“独立学习为什么 work”的理论答案。

2.3 光滑均衡

最后，多个智能体同时学习，收敛到的不是单点最优，而是一个均衡。理论上证明了在这套重构下存在光滑均衡（smooth equilibrium），并且独立学习过程会收敛到它。

这一节我讲得快，因为完整证明在参考文献里。要记住的是三步：无环结构让重构可行 → 部分可观变成马尔可夫噪声 → 存在并收敛到光滑均衡。

第三节·收敛保证：多时间尺度 Q-学习（5 分钟）

3.1 为什么需要多时间尺度

上一节说“能收敛”，这一节说“怎么收敛”。

方法是多时间尺度 Q-学习。核心思想：既然智能体互相依赖，就不让它们“以同样的速度”学习。让一部分更新得快、一部分更新得慢。快的那层在慢的那层看来近似“已经收敛静止”，慢的那层在快的那层看来近似“常数环境”。这样就把一个耦合的、非平稳的联合学习问题，解耦成了若干个各自平稳的子问题。

这个技巧的数学根基是 Borkar 的两时间尺度随机逼近理论，和 Kushner-Yin 的随机逼近 ODE 方法——用常微分方程去刻画随机迭代的极限行为。

3.2 关键条件

收敛需要一个条件，幻灯片上写的是 $\beta \leq 1 - K$ 。直观地说，它约束了不同时间尺度之间的步长比例——快慢层的更新速率之比必须落在一个范围内，太接近就重新耦合、失去解耦的好处，太悬殊就慢层学不动。

3.3 NetworkMQL：把尾流图用起来

再进一步，既然尾流依赖是一张有向无环图（DAG），那就可以让智能体沿着这张图组织学习，这就是 **NetworkMQL**（网络化多时间尺度 Q-学习）。上游先“稳定”，下游基于稳定的上游再学——正好顺着尾流传播的物理方向。经验上，这套方法在 16 机组的风场上验证过。

这一节的落点：理论不只说“能收敛”，还给了一套有步长条件、能跑在真实规模上的算法。

第四节 · 实践指导：WFCRL 基准（5 分钟）

4.1 双后端

理论要落地，需要一个标准的实验平台。我们用的是 **WFCRL**——一个专为风电场控制设计的多智能体 RL 基准，发表在 NeurIPS 2024 的数据集与基准赛道。

它最有价值的设计是双物理后端：

- **FLORIS**：稳态解析尾流模型。快，秒级出结果，但它是稳态的——没有尾流运输的时延、没有蜿蜒。
- **FAST.Farm**：动态气弹后端。它真的在算叶片的柔性变形、结构动力学、尾流的动态运输。慢，一个控制步要几秒墙钟，但它接近真实。

这个“快稳态 + 慢动态”的组合，正好对应一个自然的工作流：在 **FLORIS** 上快速选型、预训练，再上 **FAST.Farm** 检验真实效应。这条工作流是我们后面所有工作的骨架。

4.2 奖励设计与基线算法

WFCRL 提供了标准的奖励设计和一组基线算法：**IPPO**（独立 PPO）、**MAPPO**（多智能体 PPO，集中式 critic）、**QMIX**。这给了我们一个公平的对照起点。

这里插一句方法论上的坑，后面还会详细讲：基准的 `reset` 每次会重新抽风况，而功率大致正比于风速的三次方。所以如果你不把风况钉死，两次运行的功率差可能纯粹来自两次不同的抽签——单次抽签就足以造出 2.4 倍的假效应。这个坑我们踩过、定位了、钉死了。

第五节 · 我们的工作：真 MAPPO 与静/动对照（8 分钟）

5.1 我们做了什么

在 WFCRL 的基座上，我们做了三件事：

1. 实现了一套真正的 **MAPPO**——集中式 critic、CTDE（集中训练、分布执行），并接上了可选的 GRU 时序 critic；
2. 把它同时跑在 FLORIS 和 FAST.Farm 两个后端上，做受控的静态/动态对照；
3. 把整个“稳态预训练 → 动态检验”的链路做成可复现的脚本。

5.2 头条发现：差别不在功率量级，在时延与分级

这是我最想讲的一个结果。

直觉上你会以为，稳态 FLORIS 和动态 FAST.Farm 的区别是“功率数值不一样”。但我们受控对照后发现，真正的本质差别不在功率量级，而在尾流建立的时延与分级。

具体说：在动态后端里，下游的功率亏损是分两级建立的。上游一个动作，它对最下游那台机组（T3）的完整影响，要滞后大约 46 个控制步才显现——而一个控制步只有 3 秒。

这个发现有直接的算法含义：它是"记忆型策略"的物理依据。如果动作的后果要过 46 步才完全显现，那么一个无记忆的策略是看不清自己在做什么的——这正是集中式、带时序记忆的 critic (GRU) 应该相对独立学习拉开差距的场景。我们也界定了 GRU 在当前设置下的局限，没有夸大它的作用。

5.3 方法论：把假效应钉死

回到刚才那个坑。基准的 `reset` 重抽风况 + 功率正比于风速三次方，单次抽签就能造 2.4 倍假效应。

我们的处理是：做后端对照、网络对照时，必须把风速钉死（`-wind-speed` 或 `pin:U`），风向统一到 270 度沿机列方向。这样比较的才是"两个后端 / 两个网络的差别"，而不是"两次风况抽签的差别"。已定位、已钉死、已改正结论——这条方法论本身就是一个可复现的贡献。

5.4 小结这一节

这一节的落点：我们把理论保证（为什么独立学习 work）和工程现实（连续动作、深度网络、高保真动态）之间的缝隙，做成了可测量的实验——而不是停在"理论上应该行"。

第六节 · 系统架构：从脚本到应用（9 分钟）

这一节是本次汇报相对上一版新增最多的部分，讲慢一点。

6.1 目标形态

前面所有的可视化，本质上都是脚本的附属品——布局由 `env_id` 反查一张常量表，数据通道写死在代码里。这一节，我们把它重构成一个应用：一切由场景文件决定，界面只是这个场景的视图。

架构是六层，下层不知道上层存在：

- **L0 物理**：FAST.Farm 或 FLORIS；
- **L1 场景**：一份 YAML，定义机位、机型、来流、控制量；
- **L2 通道**：传感器即订阅源，开关同时管可见性和采样；
- **L3 策略 + 安全约束**；
- **L4 应用外壳**：四面板加 3D 视图，训练跑后台线程；
- **L5 汇报**：本文档和可复现脚本。

关键点：每一层都有独立的验收脚本，判据全部落在可观测量上——改 YAML 坐标画面和仿真一起变、取消订阅采样计数停住、指令与执行逐位一致、训练中界面不卡。不是"没抛异常"，是"能被自动测到对了"。

6.2 L2 数据通道：订阅是真的停采样

通道等于传感器加订阅开关。关掉一路通道，要真的省下计算——激光雷达的视线插值、相机的离屏渲染——否则"订阅"就只是个显示复选框。所以验收判据写成两条：采样计数停住，并且画面像素变少（同一相机下从 47419 降到 30450）。

更重要的是三档保真度，这不是 UI 美化：

- **DIRECT**（后端直读）：可以进奖励、约束、结论；
- **DERIVED**（由直读量导出）：同上，但必须注明推导；
- **SYNTH**（合成/代理）：只能用于感知层。

为什么这栏是硬要求？因为 FAST.Farm 不向 **Python** 暴露实时流场——界面上你看到的那片尾流，其实是同布局 **FLORIS** 稳态解做的代理，它没有输运时延、没有蜿蜒。如果把这片渲染当成动态物理结论去解释，就是把画得像当成了是真的。所以界面上每一路都带保真度标签和来源说明，合成量进不了奖励和约束。一张图能否作为证据，取决于它标注了什么，而不是它画得多像。

6.3 L3 安全约束：仿真器会静默改写你的动作

这是整个系统里我认为最有价值的一块。策略输出的，不等于机组执行的。我们定位了三处静默改写：

- 单步增量限幅（`mdp.py`）：偏航 $\pm 5^\circ$ 、桨距 $\pm 1^\circ$ 、转矩 ± 1000 牛·米；
- 状态限幅：偏航累计被夹在 $[-40^\circ, 40^\circ]$ ；
- 执行机构占空比（`multiagent_env.py:196-207`）：占空比超过 0.1 时，整步指令置零——不是限幅，是归零。

还有两处更隐蔽的：桨距其实是下界语义（`DISCON.F90:523`，低于基线的指令不生效）；转矩是完全顶替基线（动作上界只有额定值的 45.9%，直接下发就超速）。

最刺眼的一个数：偏航执行机构速率 $0.3^\circ/\text{秒}$ ，占空比上限 10%，控制步 3 秒——可持续动作只有 $0.09^\circ/\text{步}$ ，而动作空间是 $\pm 5^\circ$ ，相差 55.6 倍。

不显式建模的后果不是“学得慢”，而是学到一串从未被执行过的动作，且训练曲线上什么都看不出来。我们的约束层把每次改写记成一个带源码出处的事件，验收判据是它的预测与环境实际执行逐位一致——40 步 0 分岔。

6.4 L3 一个被修正的判据：超速要用转矩判

插一个我们自己纠错的例子，因为它可迁移。

最初判超速，是看转速是否超阈值。但这不成立：转速不是直接测量的，是由 $\omega = P/(\eta T)$ 反解出来的，而且驱动器已经在 20 rpm 处截断了。在截断上限附近设阈值，等于在自己造的天花板下猜——19.9 和 20.1 的区别来自截断，不来自物理。

改正是：判据换成发电机转矩。当转矩小于额定的 0.3 倍时，反解的分母趋零，判“反解发散”；否则判超速。并且补了一个反向用例——“19.9 rpm 加额定转矩必须判超速”，否则“发散”会变成万能借口，任何异常都能归给数值问题，约束层就失去了报警能力。

可迁移的教训：当一个量是反解出来的、且上游已被截断，就不能拿它当判据——要回到那个未经处理的原始量上去。

6.5 L4 应用外壳：训练在跑，界面不能卡

硬约束是 FAST.Farm 一个控制步 2 到 3 秒墙钟。如果压在事件循环里，界面就每 3 秒才动一下——拖不动视角、点不了按钮。

线程规矩（违反就白屏或段错误）：工作线程跑物理和 PPO，只写纯数值快照；主线程只读快照、只碰 VTK 的 actor。因为 VTK 的 actor 绑在创建它的那个渲染窗口上，跨线程改它的变换矩阵是未定义行为。

这里有一个我很得意的定位过程。实测最差的一次卡顿是 3144 毫秒——恰好一个控制步。直觉是“工作线程攥住了 GIL”。但我们没有继续猜，而是把这个间隔拆开来量：

- `sleep` 超时（意味着 GIL 被别人占）：实测小于 100 毫秒；
- `processEvents`（意味着主线程自己在算）：飙到 3144 毫秒。

这两个判据是互斥的，结论就直接了——GIL 是无辜的，是主线程自己把自己卡住了。再逐层下钻，找到两处同步计算：FLORIS 稳态解每步 0.24 到 0.36 秒、叶片柔性变形求解中位数 192 毫秒（要重算 8000 多个顶点还要做扫塔间隙搜索）。把这两个都搬进求解线程，主线程只留数组赋值——3144 毫秒降到 103 毫秒。

教训：卡顿要分解测量，不要凭直觉甩锅给 GIL。

6.6 L3 约束入回路 —— 这次的新工作

前面说的约束层，此前只是事后记录改写事件。这次我们把两处约束真正接进了学习回路，让策略在训练时就“看得见、躲得开”。

具体加了什么、怎么加的：

- 占空比余量入观测（`--obs-duty`）：给观测追加一列“剩余占空比预算”，观测维度从 3 变成 4。这样策略看得见自己下一个动作会不会被整步清零。
- 占空比惩罚入奖励（`--duty-penalty`， $\lambda=0.5$ ）：动作被清零时，按被吃掉的幅度给一个负奖励。把“下发了却没执行”的空动作记成代价。
- 占空比口径改成滑动窗口：从逐步 10% 硬夹，改成尾随 10 步累计上限 30%——这更贴合真实执行机构的预算语义，而不是逐步瞬时限幅。

措辞上我要说清楚：这不是一个“让策略更强”的技巧。约束一直都在（就是上面那三处静默改写），区别只是策略此前看不见它们、于是学到一串从未被执行的动作。我们做的是把仿真器本来就在做的改写，变成策略可以优化的信号。

6.7 D5 实测：平功率本身就是结论

我们跑了 40 轮真 FAST.Farm 训练，三机错列布局、8 米/秒来流。结果分三部分读：

第一，功率曲线：全程在 3.108 到 3.145 兆瓦之间抖动，前 5 轮到后 5 轮只涨了 0.15%——没有系统性增益。

第二，但训练流程本身是健康的：critic 的 explained variance 峰值到了 0.96，价值损失下降了 4 个数量级。这说明“没学到增益”不是流程 bug，学习机制在正常工作。

第三，看学到的策略：我把训练好的 actor 拿出来，喂各种偏航角，看它输出什么动作。结果是——在每一个偏航角，它都把动作压向 0，策略的平均偏航只有 0.93 度，远远够不到理论最优的 20 度。

为什么？这不是失败，是测量出了一个物理事实。可持续偏航 0.09 度每步，乘以 170 步的回合，上限大约 15 度；再加上占空比惩罚把大动作往回压——20 度的最优解，在这个回合长度里物理上就够不到。

所以这条平功率曲线，本身就是“约束绑定”的直接证据：我们把“回合长度乘以偏航速率上限、让最优解不可达”这件事，测了出来。

解法也很明确，是下一轮的三个方向：加长回合、放大动作缩放、或换成 reference 奖励（让策略看到相对增益而不是绝对功率值）。

第七节·路线图：四阶段目标形态（5 分钟）

我们把整个项目组织成四个阶段，讲一下当前位置：

- ① 物理仿真应用——Gazebo/Isaac Sim 式的界面，消息通道可订阅、开关立即反映在三维视图上。已有：场景文件驱动、四面板、通道开关连采样和像素。待做：拖拽式场景编辑器、多切面和等值面、尾流 DAG 叠层。
- ② 多模态数据——相机、振动、声学、压电，基座是视觉语言模型。已有：振动和载荷通道取气弹真值、激光雷达点云、统一的观测总线。待做：RGB-D 渲染管线和真实的 VLM 推理。
- ③ 有理论依据的控制策略——Q-学习或深度 RL，输出的偏航、桨距、转矩都要经物理和安全约束校验。已有：MAPPO 加约束层、改写事件可追溯到源码行；这次约束已经入回路，40 轮真 FAST.Farm 训练跑通、测得了约束绑定效应。待做：解开回合长度乘速率上限的绑定、疲劳载荷（雨流计数 DEL）入奖励。
- ④ 市场化——按电力市场需求加风况联合调度。价格信号入观测、收益（而不是功率）入奖励、爬坡和备用约束。尚未开始。

当前位置：①和③的基座已经能运行、有自动验收；②具备数据通道但缺视觉模式；④还没开始。

7.1 更远的一步：多模态 VLM + RL

再往前看，我们想在这个“物理 + MARL + 数字孪生”的基座上，把控制升级成一个多模态感知—决策问题。物理层不动，在它周围加装：SCADA 合成、振动/IMU 通道（这是 FAST.Farm “免费”给的最强多模态通道）、三维渲染器（这是唯一需要新增工程的模式）。

VLM 有四个价值点：感知增强（识别 SCADA 看不到的可视条件，比如尾流蜿蜒、叶片结冰损伤）、高层协调器（在尾流 DAG 场景图上推理、提偏航意图、底层 MARL 执行）、语言条件奖励（用自然语言设定优先级，比如“今天优先保护前排叶片寿命”）、巡检智能体（消费相机加振动谱、闭合控制—运维回路）。

第八节·总结与致谢（2 分钟）

一条完整的叙事弧线：

1. 理论：Dec-POMDP 重构成 TI-Dec-MDP，部分可观变成马尔可夫噪声，收敛到光滑均衡；
2. 收敛：多时间尺度 Q-学习，步长条件 $\beta \leq 1-K$ ，沿尾流 DAG 组织成 NetworkMQL；
3. 基准：WFCRL 双后端、奖励设计、IPPO/MAPPO/QMIX；
4. 我们：真 MAPPO 双后端管线，受控的静/动物理对照，GRU 局限已界定；
5. 未来：多模态 VLM + RL 数字孪生。

核心贡献，用三句话概括：

- 我们把理论保证和工程现实之间的缝隙，做成了可测量的实验；
- 头条发现：静态和动态的本质差别不在功率量级，而在尾流建立的时延与分级——下游亏损分两级建立，动作对 T3 的完整影响滞后约 46 个控制步，而控制步只有 3 秒。这是记忆型策略的直接物理依据；
- 方法论：无论是把风况抽签造的 2.4 倍假效应钉死，还是把执行机构约束入回路后测出的约束绑定效应——我们坚持让“没崩”和“对了”分开，让每个结论都有可观测的判据。

这次新增的一块，是把控制从“脚本”做成了“应用”，并且把仿真器静默改写动作这件容易被忽略的事，做成了可追溯、可入回路、可测量的一层。

谢谢，欢迎提问和批评。

附：可能的提问与准备好的回答

Q：40 轮没学到增益，是不是训练量不够？

A：不是训练量的问题。critic 的 explained variance 峰值到 0.96、价值损失降了 4 个数量级，说明学习机制在正常收敛。问题在于最优解在这个回合长度里物理上不可达——可持续偏航 $0.09^\circ/\text{步} \times 170 \text{ 步} \approx 15^\circ$ 上限，够不到 20° 。加长回合、放大动作缩放或换 reference 奖励都能解，我们下一轮会做。

Q：为什么不直接放宽偏航速率，让它一步偏到位？

A：可以，但要有物理依据。 $0.3^\circ/\text{秒}$ 是 NREL 5MW 官方值，随便放宽就脱离真机了。我们更倾向改占空比口径（滑动窗口 + 上限 30%），因为它对应真实执行机构“偏完散热恢复再偏”的预算语义，是可辩护的建模改进，而不是为了出数字硬调参数。

Q：界面上那片尾流是真的吗？

A：不是动态真值。FAST.Farm 不向 Python 暴露实时流场，界面上是同布局 FLORIS 稳态解做的代理——没有输运时延、没有蜿蜒。所以我们给它打了 SYNTH 保真度标签，它进不了奖励和约束，只用于感知层展示。

Q: 多时间尺度那个 $\beta \leq 1-K$ 条件, K 是什么?

A: K 与问题的耦合结构相关, 直观上它约束了快慢时间尺度的步长比例必须落在一个范围内——太接近就重新耦合失去解耦好处、太悬殊慢层学不动。具体定义在核心参考论文里, 我这里给的是它的作用而非完整推导。

Q: GRU 时序 critic 到底有没有用?

A: 我们界定了它的局限, 没有夸大。理论上, 既然动作对下游的完整影响滞后约 46 步, 带记忆的 critic 应该在这个场景拉开差距。但在当前设置下的实测提升有限——这本身也是一个诚实的结果, 说明"应该有用"和"实测有用"之间还有工程差距要填。